目录

Provider Capability Matrix（模型能力矩阵）

一、国产模型

二、海外模型（通过合规代理商接入）

三、Claude usage 格式特殊处理

四、预冻结价格计算示例

示例 1：DeepSeek V4-Pro，中文 prompt

示例 2：GPT-5，英文 prompt

五、价格管理

Provider Capability Matrix（模型能力矩阵）

> **版本**：v2.0 **日期**：2026-06-18 **用途**：开发团队配置渠道和预冻结公式的核心参考 **变更**：基于 v1.0 修正，补充 2026 年新模型，修正 usage 格式差异

一、国产模型

能力	DeepSeek V4-Pro	DeepSeek V4-Flash	Qwen3.7-Max	Qwen3.7-Plus	GLM-5	GLM-4
Channel Type	`deepseek` (36)	`deepseek` (36)	`ali` (17)	`ali` (17)	`zhipu` (16)	`zhipu` (16)
Chat Completions	✅	✅	✅	✅	✅	✅
Embeddings	❌	❌	✅	✅	✅	✅
Function Calling	✅	✅	✅	✅	✅	✅
Vision	❌	❌	✅	✅	✅	✅
流式 usage 位置	最后一个 chunk	最后一个 chunk	最后一个 chunk	最后一个 chunk	最后一个 chunk	最后一个 chunk
usage 字段名	`prompt_tokens` / `completion_tokens`	同左	同左	同左	同左	同左
max_context	128K	128K	128K	128K	128K	128K
default_max_output	4096	4096	8192	8192	4096	4096
输入价格（¥/百万 Token）	2.00	0.13	2.40	0.80	5.00	0.10
输出价格（¥/百万 Token）	8.00	0.28	9.60	2.00	10.00	0.10

二、海外模型（通过合规代理商接入）

能力	GPT-5	GPT-4o	Claude Opus 4	Claude Sonnet 4	Gemini 2.5 Pro	Gen Flas
Channel Type	`openai` (1)	`openai` (1)	`anthropic` (14)	`anthropic` (14)	`geminiv2` (50)	`gem` (50)
Chat Completions	✅	✅	✅	✅	✅	✅
Embeddings	✅	✅	❌	❌	✅	✅
Function Calling	✅	✅	✅ (tool_use)	✅ (tool_use)	✅	✅
Vision	✅	✅	✅	✅	✅	✅
流式 usage 位置	最后一个 chunk	最后一个 chunk	`message_start` + `message_delta`	同左	最后一个 chunk	最后 chu
usage 字段名	`prompt_tokens` / `completion_tokens`	同左	`input_tokens` / `output_tokens`	同左	`prompt_tokens` / `completion_tokens`	同左
max_context	128K	128K	200K	200K	1M	1M
default_max_output	16384	16384	32768	32768	8192	819
输入价格（/*百万Token*） * *|10.00|2.50|15.00|3.00|1.25|0.075|** * *输出价格*（/百万Token）	30.00	10.00	75.00	15.00	5.00	0.30

三、Claude usage 格式特殊处理

Claude 的流式 usage 分布在两个 event 中，与其他模型不同：

```
event: message_start
data: {"type":"message_start","message":{"usage":{"input_tokens":1234}}}

... (中间 chunks) ...

event: message_delta
data: {"type":"message_delta","delta":{"stop_reason":"end_turn"},"usage":{"output_tokens":567}}
```

实现要求： - `StreamChunkHandler` 需要识别 `anthropic` 渠道类型 - 在 `message_start` 中提取 `input_tokens` - 在 `message_delta` 中提取 `output_tokens` - 合并后写入 `call_logs`

四、预冻结价格计算示例

示例 1：DeepSeek V4-Pro，中文 prompt

```
请求：2000 字中文 prompt + max_tokens=2000
模型：DeepSeek V4-Pro（输入 ¥2/百万 Token，输出 ¥8/百万 Token）

promptTokens = ceil(2000 / 1.5) = 1334 tokens
inputCost = 1334 / 1,000,000 × 200 = 0.27 分
outputCost = 2000 / 1,000,000 × 800 × 1.5 = 2.40 分
freezeAmount = max(0.27 + 2.40, 10) = 10 分 = ¥0.10
```

示例 2：GPT-5，英文 prompt

```
请求：5000 字英文 prompt + max_tokens=4000
模型：GPT-5（输入 $10/百万 Token，输出 $30/百万 Token）
汇率：7.25

promptTokens = ceil(5000 / 4) = 1250 tokens
inputCost = 1250 / 1,000,000 × 1000 × 7.25 = 9.06 分
outputCost = 4000 / 1,000,000 × 3000 × 7.25 × 1.5 = 130.50 分
freezeAmount = max(9.06 + 130.50, 10) = 139.56 分 = ¥1.40
```

五、价格管理

- `model_prices` 表存储全局基础价格（以分为单位，CNY）
- `org_model_prices` 表存储组织级覆盖（`multiplier` 字段）
- 海外模型价格 = USD × `EXCHANGE_RATE`（环境变量，默认 7.25）
- 价格变更后立即生效（无缓存延迟）

> ⚠️ **注意**：以上价格为 AI 顾问提供的参考值，开发前必须从各厂商官网验证实际 List Price。