目录

Error Handling Matrix（错误处理矩阵）

一、上游错误处理规则

二、平台错误码规范

2.1 错误响应格式（OpenAI 兼容）

2.2 错误码分类

三、SSE 流式错误处理

流式错误 JSON 格式

四、Failover 逻辑

Error Handling Matrix（错误处理矩阵）

> **版本**：v2.0 **日期**：2026-06-18 **用途**：开发团队实现网关异常处理逻辑的核心参考 **变更**：基于 v1.0 修正，统一错误码命名规范，补充 SSE 流式错误处理

一、上游错误处理规则

上游状态码	上游错误类型	Gateway 处理	重试	熔断	返回客户端
200	正常	解析 usage → Settle	—	—	200 + 响应体
400	请求格式错误	直接返回	❌	❌	400 + upstream_error
401	认证失败	标记该 Key invalid，切下一个 Key	❌	✅ Key 级	502（所有 Key 失败）
403	权限不足	直接返回	❌	✅ 渠道级	403 + upstream_error
408	请求超时	切 fallback 渠道	✅ 1 次	✅ 计数	502（全部超时）
429	限流	该 Key 冷却 60s，切下一个 Key	❌	✅ Key 级	429（全部限流）
500	服务器错误	切 fallback 渠道	✅ 1 次	✅ 计数	502
502	网关错误	切 fallback 渠道	✅ 1 次	✅ 计数	502
503	服务不可用	切 fallback 渠道	✅ 1 次	✅ 计数	502
连接超时	无响应	切 fallback 渠道	✅ 1 次	✅ 计数	502

二、平台错误码规范

2.1 错误响应格式（OpenAI 兼容）

```
{
    "error": {
        "message": "人类可读的错误描述",
        "type": "error_type",
        "code": "error_code",
        "param": null
    }
}
```

2.2 错误码分类

采用 `{category}.{specific}` 两段式命名，避免与上游错误码冲突。

鉴权错误（4xx）：

HTTP	type	code	message	触发场景
400	`invalid_request_error`	`validation_error.sensitive_word_detected`	请求包含敏感内容	敏感词拦截
400	`invalid_request_error`	`validation_error.context_length_exceeded`	请求超过上下文限制	prompt 过长
400	`invalid_request_error`	`validation_error.invalid_request`	请求格式错误	参数缺失/格式错误
401	`authentication_error`	`auth_error.invalid_api_key`	API Key 无效	Key 不存在或已禁用
403	`permission_error`	`auth_error.ip_denied`	IP 不在白名单	IP 白名单拦截
403	`permission_error`	`auth_error.model_not_allowed`	模型不在授权列表	allowed_models 拦截
429	`rate_limit_error`	`rate_limit_error.rpm_exceeded`	请求过于频繁（RPM）	Key 级限流

计费错误（4xx）：

HTTP	type	code	message	触发场景
402	`billing_error`	`billing_error.insufficient_balance`	余额不足，请充值后重试	预冻结失败
409	`billing_error`	`billing_error.idempotent_conflict`	请求正在处理中	幂等性冲突

服务器错误（5xx）：

HTTP	type	code	message	触发场景
500	`server_error`	`server_error.internal_error`	内部服务器错误	未预期异常

HTTP	type	code	message	触发场景
502	`server_error`	`server_error.upstream_error`	上游服务不可用	所有渠道失败
503	`server_error`	`server_error.service_unavailable`	服务暂时不可用	健康检查失败

三、SSE 流式错误处理

错误时机	处理方式
转发前（Freeze 后，首个 chunk 前）	Cancel 冻结金额 + 返回标准错误 JSON
转发中（已发送部分 chunk）	发送 `data: {"error":{...}}\n\n` + 关闭 SSE
客户端断开	关闭上游连接 + 按已收到 chunk 结算
上游断开（无 usage）	本地 token 估算 + 结算 + 发送 [DONE]
余额穿底	强制断开上游 + 补发 [DONE] + 按已收到 chunk 结算

流式错误 JSON 格式

```
data: {"error":{"message":"上游服务不可用","type":"server_error","code":"server_error.upstream_error"}

data: [DONE]
```

四、Failover 逻辑

```
请求 → 渠道 A（priority=1）
  ├── Key 1 失败（401）→ 标记 Key 1 invalid → 尝试 Key 2
  ├── Key 2 失败（429）→ Key 2 冷却 60s → 尝试 Key 3
  ├── Key 3 失败（500）→ 渠道 A 失败计数 +1
  │
  ▼ （所有 Key 失败）
  渠道 A 失败计数 ≥ 5? → 熔断
  │
  ▼
  渠道 B（priority=2，同模型）
  ├── Key 1 成功 → 返回
  └── Key 1 失败 → 继续...
  │
  ▼ （所有渠道失败）
  返回 502 + server_error.upstream_error
```

关键规则：– 只重试 1 次（`MAX_RETRY_COUNT=1`） – 只做同模型重试，不做跨模型 Fallback – 400 错误不重试（客户端问题） – 401/429 不触发渠道级熔断（Key 级处理） – 408/500/502/503 触发渠道级熔断计数